


# SpecTrace

Проверяемый ассистент тест-дизайна: от нормативных требований спецификации к матрице трассировки с видимыми пробелами покрытия

## ПРОБЛЕМА

Чат-ассистент быстро пишет тест-кейсы по спецификации, но отличить выдуманное требование от настоящего можно, только перечитав весь документ — ту самую работу, которую он должен был снять.

# Подход: модель предлагает, код проверяет



🔍 Модель возвращает только текст цитаты — место в документе находит код.

📖 Каждый вызов модели заэкширован: прогон воспроизводится офлайн, без ключа.

⚠️ Цитаты нет в тексте — требование отброшено и показано отдельно; цитата встречается дважды — решает человек.

# Выводы — три отдельных измерения

## 1 · ТОЧНОСТЬ ЦИТИРОВАНИЯ

**81,3 % → 0 %**

цитат не совпали с текстом дословно:  
простой промпт — 13 из 16, конвейер — 0  
из 18; RFC 6902, одна модель, один  
верификатор

**Это несовпадение цитат, в основном  
из-за кавычек, а не доля выдуманных  
требований.** На RFC 10050: чат — 9,5 %,  
простой промпт — 9,1 %, конвейер —  
3,3 %

headline.md · error-analysis.md §2

## 2 · ПОЛНОТА ИЗВЛЕЧЕНИЯ

**63,2 %**

полнота итогового реестра: 12 из 19  
эталонных требований при точности  
100 %; до проверки — 94,7 %

**6 требований ждут решения человека.  
Ноль ошибок цитирования не означает  
полного покрытия спецификации.**

headline.md · error-analysis.md §3

## 3 · КАЧЕСТВО ТЕСТ-КЕЙСОВ

**11 · 9 · 3**

из 23 тест-кейсов приняты как есть,  
исправлены и отклонены

**Рецензент один — автор.**

experiments/review/ · error-analysis.md §9

# Мой вклад и обоснование решений

## Что сделал я

Код и большую часть документов написал ИИ-агент Claude Code — по моим задачам и правилам.

- замысел, рамки и семь принципов — Blueprint, одобрен 16 сентября
- задачи агенту по вехам, приёмка каждой вехи по критериям
- эталон: 19 требований по правилам, замороженным до разметки
- ответы чата для сравнения; выбор RFC 10050
- рецензия всех 23 кейсов и 4 вопросов очереди
- развёртывание стенда; 7 октября — перевод в офлайн

## Решения и почему

- **Модель отдаёт только цитату, место находит код:** позицию можно проверить, смещение от модели — нет
- **Цитаты нет — отбросить, найдена дважды — человеку:** система не угадывает
- **Кэш каждого вызова, температура 0:** повтор без ключа, CI сравнивает побайтно
- **Flash-Lite вместо Flash:** у Flash 20 запросов в день — меньше одного прогона

# Границы: что результаты не доказывают

| Ограничение                                                                                                                 | Что это значит                                                                                                                                                                                                                                                                                                                 |
|-----------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Маленькие выборки. Эталон — 19 требований одного документа, размечал один человек — я. Каждую ветку запускали один раз      | Цифры описывают именно эти прогоны, а не общую закономерность: доверительных интервалов нет, согласие разметчиков не измерить. На RFC 10050 ветки различаются на 1–2 утверждения — повторный запуск мог бы это изменить, поэтому выводов из этой разницы я не делаю                                                            |
| RFC 6902 модель, скорее всего, уже видела. Он опубликован в 2013 году                                                       | Модель могла не читать документ, а «вспоминать» его, поэтому результат на RFC 6902 может быть завышен. Для проверки взял RFC 10050: он вышел в сентябре 2026, после даты среза знаний модели, хотя черновики были открыты раньше. На нём ветки близки: чат — 9,5 %, простой промпт — 9,1 %, конвейер — 3,3 % ненайденных цитат |
| T3 выполнено не полностью. Главное — не выполнено требование NFR-04: провайдера модели должно быть можно сменить настройкой | Провайдер — только Gemini: он задан в коде, и подключение к модели написано одно. Сменить провайдера — это новая реализация и правка кода, а не строчка в настройках, и работу с другим провайдером я не показал. Остальные частично выполненные пункты перечислены в записках о приёмке M1 и M2                               |

# Проверить самостоятельно

ЧТО И ПОЧЕМУ

[github.com/KaunazDagaz/SpecTrace-docs](https://github.com/KaunazDagaz/SpecTrace-docs)

КОД И ПРОВЕРКИ

[github.com/KaunazDagaz/SpecTrace-dev](https://github.com/KaunazDagaz/SpecTrace-dev)

СТЕНД, ОФЛАЙН

[spectrace-5zrm6uxcja-lz.a.run.app](https://spectrace-5zrm6uxcja-lz.a.run.app)