


SpecTrace

Проверяемый ассистент тест-дизайна: от нормативных требований спецификации к матрице трассировки с видимыми пробелами покрытия

ПРОБЛЕМА

Чат-ассистент быстро пишет тест-кейсы по спецификации, но отличить выдуманное требование от настоящего можно, только перечитав весь документ — ту самую работу, которую он должен был снять.

Подход: модель предлагает, код проверяет



🔍 Модель возвращает только текст цитаты — место в документе находит код.

📖 Каждый вызов модели заэкширован: прогон воспроизводится офлайн, без ключа.

⚠ Цитаты нет в тексте — требование отброшено и показано отдельно; цитата встречается дважды — решает человек.

✓ Никаких выводов о полноте: только «в реестре нет непокрытых требований».

Что подтверждает результат

81,3 %

цитат наивного промпта нет в документе дословно; у конвейера 0,0 % — RFC 6902, та же модель и та же проверка
experiments/headline.md

F1 77,4 %

против эталона из 19 требований:
точность 100 %, полнота 63,2 %
experiments/headline.md

6 из 19

требований ждут решения человека:
цитата встречается дважды или прочитана двояко — до проверки полнота 94,7 %
experiments/error-analysis.md §3

3,3 %

цитат конвейера нет в RFC 10050, вышедшем после даты среза знаний модели; у наивного промпта 9,1 %, у чата 9,5 %
experiments/headline.md

11 · 9 · 3

из 23 тест-кейсов приняты как есть, исправлены и отклонены; один рецензент — автор, 21 решение принято с мнением агента о каждом кейсе
experiments/error-analysis.md §9

1 команда

воспроизводит прогон офлайн, без ключа: файлы совпадают с закоммиченными, кроме времени запуска и коммита; CI — Linux и Windows
README, раздел «Reproduce»

Границы: что результаты не доказывают

Ограничение	Что из этого следует
Один аннотатор, 19 требований в эталоне	нет оценки согласия разметчиков; качество измерено на одном документе
Одна модель, по одному прогону на ветку	разница в 1–2 утверждения на RFC 10050 — в пределах того, что изменит повторный прогон
RFC 6902 модель, скорее всего, видела при обучении	поэтому второй документ, опубликованный после даты среза знаний (черновики — раньше); на нём ветки близки
Выдуманных требований не нашлось ни в одной ветке	проверка отсеяла неточные цитаты и передала дубли человеку; выдумки ловить не пришлось
Публичный сервис вызывает модель на бесплатной квоте	условия Gemini API разрешают открывать клиент пользователям в ЕЭЗ только на платных сервисах; решение от 1 октября и принятый риск — в research/decisions.md

Проверить самостоятельно

ЧТО И ПОЧЕМУ

github.com/KaunazDagaz/SpecTrace-docs

КОД И ПРОВЕРКИ

github.com/KaunazDagaz/SpecTrace-dev

ДЕМОНСТРАЦИЯ

spectrace-5zrm6uxcja-lz.a.run.app

ПОВТОРИТЬ ПРОГОН БЕЗ КЛЮЧА И БЕЗ СЕТИ

```
dotnet run --project src/SpecTrace.Cli -- run --document corpus/rfc6902.txt --offline --out runs/reference
```

Открытый вопрос для диплома: позволяет ли строгая проверка дешёвой модели сравняться с дорогой моделью, которой доверяют без проверки?